


Introducción a la gestión de datos antiguos


Constanza de la Fuente Castro





¿A qué tipo de preguntas puede contribuir el ADN antiguo?




¿Qué información podemos recuperar?




Podemos recuperar ADN de muchos tejidos y contextos, pero no está intacto




¿Cómo se ve reflejado este daño?



Fragmentos pequeños
(principalmente vía depurinación)



Alteraciones químicas
(patrón de desaminación)




ADN en baja proporción versus
moléculas de otros organismos

¿Qué información podemos recuperar?




Ancient DNA



Chemical modifications
Fragmentation

Contamination



Nuclear DNA


3,000,000,000 base pairs

Mitochondrial DNA

16,500 base pairs

+Patógenos!


¿Qué información podemos recuperar?




KNOWABLE MAGAZINE

- ♦ DNA nuclear: diploide, dos copias por célula. Aproximadamente 3 mil millones de bases. Heredado de madre y padre
- ♦ DNA mitocondrial: haploide, cientos a miles de copias por célula. Circular. 16569 de bases. Sólo herencia materna.


¿Qué información podemos recuperar?



KNOWABLE MAGAZINE





¿Qué información podemos recuperar?



- ♦ Las primeras investigaciones de ADN antiguo se publicaron a mediados de 1980.
- ♦ Hasta el ~2010, casi la totalidad de los estudios en humano estaban basados en ADN mitocondrial.
- ♦ ADNmt: muchas copias por célula y fácil de analizar. Sin embargo, representa sólo una fracción del genoma completo y de nuestra historia.
- ♦ ¿Qué cambió?

El *boom* genómico


- ♦ Avances metodológicos: secuenciación masiva y herramientas informáticas
- ♦ Conocimiento del genoma humano.
- ♦ Numero creciente de genomas antiguos publicados + expansión temporal.
- ♦ Principalmente últimos 50.000 años
- ♦ Los genomas antiguos “*más antiguos*”:
 - Neanderthal: 430.000
 - Caballo: 560-780.000
 - Mamut: 500.000 – 1.1M años!
 - Sedimentos: 2M años!




Número acumulado de genomas humanos antiguos publicados (hasta 2024). Figura propia, hecha en base a AADR.

El *boom* genómico

- ♦ Numero creciente de genomas antiguos publicados + expansión temporal.
- ♦ Avances metodológicos: secuenciación masiva y herramientas informáticas
- ♦ Conocimiento del genoma humano.
- ♦ Principalmente últimos 50.000 años
- ♦ Los genomas antiguos “*más antiguos*”:
 - Neanderthal: 430.000
 - Caballo: 560-780.000
 - Mamut: 500.000 – 1.1M años!
 - Sedimentos: 2M años!



Generación masiva de datos en todo el mundo (?)





ADN antiguo: características y estrategias de análisis

- Fragmentos pequeños y en baja proporción
- Alteraciones post-mortem (patrones de daño)
 - Estrategias en laboratorio:
 - ◆ Aislamiento
 - ◆ Esterilidad
 - ◆ Limpieza
 - ◆ Volumen de muestras
 - ◆ Controles negativos
 - Estrategias de análisis:
 - ◆ Análisis de fragmentos pequeños y ensamblado
 - ◆ Presencia de daño
 - ◆ Evaluar variantes según probabilidad de daño (tipo de sustitución y posición en fragmento)
 - ◆ Evaluar contaminación




Trabajo de laboratorio: desde la toma de muestra a la secuenciación




Dos pasos de secuenciación:

- Evaluación/Screening
- Aumentar profundidad

Procesamiento de datos: flujo de trabajo




Procesamiento de datos: flujo de trabajo



Sequencing


Sanger

- Known as “chain termination method”
- Single DNA fragment at the time



NGS


- Sequencing by Synthesis
- Massively parallel



Sanger sequencing

- Fasta format:

Chromatogram:



One sequence:

```
>sample1  
AGTGCCTGTTTC
```

Several sequence:

```
>sample1  
AGTGCCTGTTTG  
>sample2  
AGTCCCTGTTTC  
>sample3  
AGTGCCTGTTTG  
>sample4  
AGTCCCTGTTTC  
>sample5  
AGTGCCTGTTTC  
>sample6  
AGTCCCTGTTTC  
>sample7  
AGTGCCTGTTTG
```

Next Generation Sequencing (NGS)



```
@NB551024.47:H3G2YBGXC:1:11101:2093:1039 1:N:0:0
TGACTNTTTAAAAAAATCCGTAACCTCTTTTCATAACTTTTTGTAACTTAGATCGGAAGAGAACAGCTCTGAACCTCATTCA
+
AAAAA#EEEEEEEEEEEEEEA//EEE/EEEEEEEA//EEE//EEAEEEEEEE/</EEEE/EE6EE/EAA/EAAE<EAE<///EEE
@NB551024.47:H3G2YBGXC:1:11101:14802:1039 1:N:0:0
CCTTTNACTCTGTTGATATTATCTTTTGATGCAGAAATGTTTCATTTTCACAAATCCAGTTTGTCTACAATTGATAAGATCGGAAGAG
+
AAAAA#EEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEE
@NB551024.47:H3G2YBGXC:1:11101:19434:1039 1:N:0:0
ATACANTTGTATTTCTGCAAAACAGCAACAATTAGAAAATGAAATGTAAGTTTTTTTGATTTTAAAAATTAAGATCGGAAGACACAG
+
AAAAA#EEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEE
@NB551024.47:H3G2YBGXC:1:11101:13466:1039 1:N:0:0
CTGACNTTAAATAATTTTGATTCTAGTTTAATTTCTCAGGAACCTAAATCTAGAGATCGGAAGACACAGCTCTGAACCTCAGTCA
+
AAAAA#EEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEE
@NB551024.47:H3G2YBGXC:1:11101:20853:1039 1:N:0:0
TACATNTCCACAAAAACAGACTTAACATTATTAATAACAGGTATATCTAAAGATATATCAAAGTACTCATAATACAAACATACTAAGA
+
AAAAA#E//E6/EEEE/E<AE/EA//E/EEAE/A/E/EEE/E///E6///E/<E/E///E///E///A///E///EEE
@NB551024.47:H3G2YBGXC:1:11101:17333:1039 1:N:0:0
GGTGANCCAAGGTCAAAC TGGAAT TATAGTCACAGTATAGATATAGATTATAATATTACAAACCCTAAGATAGCTAATAATTGAGAT
+
```

Sequencing

FASTQ

FASTQ format

Phred +33 encoded,
using ASCII characters to
represent the numerical
quality scores.

Header (starting with @)

DNA sequence

Separator (just +)

Quality scores per base

```
@NB551024:47:H3G2YBGXC:1:11101:2093:1039 1:N:0:0
TGACTNTTTAAAAAAATCCCGTAACTTCTTTTTCATAACTTTTTTGTAACTTAGATCGGAAGAGAACACGTCTGAACTCCATTCA
+
AAAAA#EEEEEEEEEEEEEA//EEE/EEEEEEEA//EEE//EEAEAAAAEE/EE/EEEE/EEE6EE/EAA/EAAAE<EAAEE<//EEE
@NB551024:47:H3G2YBGXC:1:11101:14802:1039 1:N:0:0
CCTTTNACTCTGTTGATATTATCTTTTGATGCAGAAATGTTTTCATTTTCACAAAATCCAGTTTGTCTACAATTGATAAGATCGGAAGAG
+
AAAAA#EEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEE
@NB551024:47:H3G2YBGXC:1:11101:19434:1039 1:N:0:0
ATACANTTGTATTTCTGCAAACAGCAACAATTAGAAAATGAAATGTAAAGTTTTTTTGATTTTAAAAATTAAGATCGGAAGAGCACACG
+
AAAAA#EEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEE
@NB551024:47:H3G2YBGXC:1:11101:13466:1039 1:N:0:0
CTGACNTTAAATAATTTTGATTCTAGTTTAATTTCTCAGGAACCTAAATTCTAGAGATCGGAAGAGCACACGTCTGAACTCCAGTCA
+
AAAAA#EEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEE
@NB551024:47:H3G2YBGXC:1:11101:20853:1039 1:N:0:0
TACATNTCCAAAAACAGACTTAACATTATTAAATAACAGGTATATCTAAAGATATATCAAAGTACTCATAATACAAACATACTAAGA
+
AAAAA#E/EE//E6/EEEE/E<AE/EA//E/EEAE/A/E/EEE/E///E6///E/<E/E///E///E///A///E///E/EEE
@NB551024:47:H3G2YBGXC:1:11101:17333:1039 1:N:0:0
GGTGANCCAAGGTCAAAGTGAATTATAGTCACAGTATAGATATAGATTATAAATATTACAAACCCTAAGATAGCTAATAAATTGAGAT
+
```


FASTQ format

The quality score of a base, also known as a Phred or Q score, is an integer value representing the estimated probability of an error, i.e. that the base is incorrect. If P is the error probability, then:

$$P = 10^{-Q/10}$$

$$Q = -10 \log_{10}(P)$$

Phred +33 encoded, using ASCII characters to represent the numerical quality scores.

Quality scores per base


```
TTAGATCGGAAGAGAACACGTCTGAACTCCATTCA
</EEEE/EEE6EE/EAA/EAAAE<EAAE<///EEE
AAATCCAGTTTGTCTACAATTGATAAGATCGGAAGAG
```

```
+
AAAA#EEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEE
@NB551024:47:H3G2YBGXC:1:11101:19434:1039 1:N:0:0
ATACANTTGTATTTCTGCAAACAGCAACAATTAGAAAATGAAATGTAAAGTTTTTTTGAATTTAAAAATTAAGATCGGAAGAGCACACG
+
AAAA#EEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEEE
@NB551024:47:H3G2YBGXC:1:11101:19434:1039 1:N:0:0
CTGACNTTAAATAATTTT
```


ASCII_BASE=33 Illumina, Ion Torrent, PacBio and Sanger

Q	P_error	ASCII	Q	P_error	ASCII	Q	P_error	ASCII	Q	P_error	ASCII
0	1.00000	33 !	11	0.07943	44 ,	22	0.00631	55 7	33	0.00050	66 B
1	0.79433	34 "	12	0.06310	45 -	23	0.00501	56 8	34	0.00040	67 C
2	0.63096	35 #	13	0.05012	46 .	24	0.00398	57 9	35	0.00032	68 D
3	0.50119	36 \$	14	0.03981	47 /	25	0.00316	58 :	36	0.00025	69 E
4	0.39811	37 %	15	0.03162	48 0	26	0.00251	59 ;	37	0.00020	70 F
5	0.31623	38 &	16	0.02512	49 1	27	0.00200	60 <	38	0.00016	71 G
6	0.25119	39 '	17	0.01995	50 2	28	0.00158	61 =	39	0.00013	72 H
7	0.19953	40 (	18	0.01585	51 3	29	0.00126	62 >	40	0.00010	73 I
8	0.15849	41)	19	0.01259	52 4	30	0.00100	63 ?	41	0.00008	74 J
9	0.12589	42 *	20	0.01000	53 5	31	0.00079	64 @	42	0.00006	75 K
10	0.10000	43 +	21	0.00794	54 6	32	0.00063	65 A			

fastqc result: Quality scores per base (all reads)



Procesamiento de datos: flujo de trabajo



AdapterRemoval

Adapters contain:

- Sequences that allow DNA fragments to bind and generate cluster on the flow cell
- Sequencing primer binding sites to initiate sequencing
- Index sequence (index 1, 2 or both): sample identifiers. It allows pooling multiple samples in a single sequencing run

Technical Note | [Open Access](#) | [Published: 12 February 2016](#)


AdapterRemoval v2: rapid adapter trimming, identification, and read merging

[Mikkel Schubert](#) , [Stinus Lindgreen](#) & [Ludovic Orlando](#)


[BMC Research Notes](#) **9**, Article number: 88 (2016) | [Cite this article](#)



Pre-AdapterRemoval



Post-AdapterRemoval




Procesamiento de datos: flujo de trabajo



Sequencing



FASTQ



Mapping or Aligning to
reference genome
(BWA)



BAM



BAM format



Reads (fastq)



Reference Genome (fasta)



Mapping



GATCAGCAACGTACCGCCAGATACCGGGAACATACCATACGA

TAAGCGACGTA

read1

TACCGCGAGATAC

read2

BAM format

Header section

@SQ: Reference sequence dictionary

SN: name

LN: length

@RG: Read group (important if merging different libraries)

@PG: Program

[illegible]

Reads: name (same as fastq), flag, chromosome name (SN), position, mapping quality, cigar, RNEXT, PNEXT, Sequence, per base quality, read group information.

BWA (Burrow Wheeler Aligner)

Specific to ancient DNA

BWA mem *versus* aln

Seed disable

```
10001 10011 10021 10031 10041 10051 10061
N**TAACCCCTAACCCCTAACCCCTAACCCCTAACCCCTAACCCCTAACCCCTAACCCCTAACCCCTAACCC
M .....M.....M...
CCC.....
CCC.....
ATC.....
g**.....
ATC.....
atc.....
.....C.....C...
.....C.....C...
.....
```


“BWA is a software package for mapping low-divergent sequences against a large reference genome, such as the human genome.”

BAM format: filters


- Remove unmapped reads
- Remove alignments with mapping quality below a threshold (usually 30)
- Remove duplicates (PICARD MarkDuplicates)
- Indel Realignment (GATK)

Softwares:
-SAMTOOLS
-PICARD
-GATK

Procesamiento de datos: flujo de trabajo




DAMAGE: MAPDAMAGE



Fragmentation pattern

DAMAGE: MAPDAMAGE



Deamination pattern


Procesamiento de datos: flujo de trabajo



Sequencing



FASTQ



Mapping or Aligning to
reference genome
(BWA)




BAM



Variant Calling (GATK,
bcftools, ATLAS)



VCF



VCF: The Variant Call Format

```
##fileformat=VCFv4.2
##FILTER=<ID=PASS,Description="All filters passed">
##source=atlas
##FORMAT=<ID=GT,Number=1,Type=String,Description="Genotype">
##FORMAT=<ID=DP,Number=1,Type=Integer,Description="Total Depth">
##contig=<ID=1>
##contig=<ID=2>
##contig=<ID=3>
##contig=<ID=4>
##contig=<ID=5>
##contig=<ID=6>
##contig=<ID=7>
##contig=<ID=8>
##contig=<ID=9>
##contig=<ID=10>
##contig=<ID=11>
##contig=<ID=12>
##contig=<ID=13>
##contig=<ID=14>
##contig=<ID=15>
##contig=<ID=16>
##contig=<ID=17>
##contig=<ID=18>
##contig=<ID=19>
##contig=<ID=20>
##contig=<ID=21>
##contig=<ID=22>
##bcftools_mergeVersion=1.6+htslib-1.7-36-g11813d5
##bcftools_mergeCommand=merge -Ov -l bamlist.altura.txt; Date=Wed Feb 24 13:27:47 2021
#CHROM  POS      ID      REF      ALT      QUAL      FILTER  INFO      FORMAT  Aconcagua  Plomo  Quewar  Toro
1       565433  .       C       T       .       .       .       GT:DP    0:2      0:1    0:3     0:8
1       752566  .       G       A       .       .       .       GT:DP    1:1      1:4    0:2     1:5
1       753541  .       G       A       .       .       .       GT:DP    0:3      0:2    1:5     0:5
1       754105  .       C       T       .       .       .       GT:DP    0:6      0:2    0:4     0:8
1       754182  .       A       G       .       .       .       GT:DP    1:1      1:1    0:4     1:4
```

Meta-information:

E.g. ##INFO, ##FORMAT, ##FILTER

Header: #CHROM POS ID REF ALT
QUAL FILTER INFO FORMAT IND1
IND2...

VCF: The Variant Call Format

#CHROM	POS	ID	REF	ALT	QUAL	FILTER	INFO	FORMAT	S1	S2	S3	S4
1	565433	rs102	C	T	45	.	.	GT:DP	0/0:2	0/1:1	0/1:3	1/1:8
4	752566	rs450	G	A	32	.	.	GT:DP	0/1:4	1/1:3	0/1:7	1/1:10



0



1



: separated

GT: genotype
DP : read depth

Pseudo-haploid genomes low coverage aDNA

S1	S2	S3	S4
0:2	0:1	0:3	1:8
0:4	1:3	0:7	1:10