

Módulo 2:

Datos de genotipos: Control de Calidad y Parentesco

Curso pre-congreso ALAB-Juan Comas
Ciudad de México.

Módulo 2

Datos de genotipos: Control de Calidad y Parentesco

- Objetivos

- repasar la organización de los datos de genotipos,
- realizar algunos pasos de control de calidad,
- estimar el grado de parentesco entre individuos, y
- generar datos listos para realizar análisis de genética de poblaciones.

Datos que se analizan

- Matriz de genotipos

	SNP1 (chr1) A	SNP2 (chr1) A	SNP3 (chr2) C	SNP4 (chr2) A	SNP5 (chr2) C	SNP6 (chr3) A	SNP7 (chr3) G
Ind1.PopA	A A=2	A G=1	C T=1	A C=1	C C=2	A A=2	G G=2
Ind2.PopA	A T=1	A G=1	C T=1	A C=1	C G=1	A T=1	G T=1
Ind3.PopA	T T=0	G G=0	C C=2	A C=1	C C=2	A T=1	T T=0
Ind4.PopB	A T=1	A A=2	T T=0	A A=2	C G=1	T T=0	T T=0
Ind5.PopB	A T=1	A A=2	C T=1	A A=2	G G=0	T T=0	G T=1
Ind6.PopB	T T=0	A G=1	C T=1	A A=2	G G=0	A T=1	G T=1
Ind7.PopB	T T=0	A A=2	T T=0	A C=1	C G=1	A T=1	G G=2

- Matriz de frecuencias

	SNP1 (chr1) A	SNP2 (chr1) A	SNP3 (chr2) C	SNP4 (chr2) A	SNP5 (chr2) C	SNP6 (chr3) A	SNP7 (chr3) G
PopA	0.5	0.333	0.66	0.5	0.833	0.666	0.5
PopB	0.25	0.875	0.25	0.875	0.25	0.25	0.5

PLINK binary y EIGENSTRAT.

3 ficheros principales:

- Matriz de genotipos. Binario (no legible como texto):
- Información de las variantes analizadas
- Información de los individuos analizados
- Para EIGENSTRAT, (fichero de genotipos no binario)—> común usar sufijo .txt

	PLINK	PACKED EIGENSTRAT	EIGENSTRAT
Genotipos	.bed	.geno	.geno.txt
Variantes	.bim	.snp	.snp.txt
Individuos	.fam	.ind	.ind.txt

PLINK binary y EIGENSTRAT.

Fichero de anotación de las variantes

Información	.snp	.bim
ID de la variante	Columna 1	Columna 2
Cromosoma	Columna 2	Columna 1
Posición genética	Columna 3	Columna 3
Posición física	Columna 4	Columna 4
Alelo 1	Columna 5	Columna 5
Alelo 2	Columna 6	Columna 6

```
1 rs3094315 0.020130 752566 G A
1 rs12124819 0.020242 776546 A G
1 rs28765502 0.022137 832918 T C
1 rs7419119 0.022518 842013 T G
1 rs950122 0.022720 846864 G C
1 rs113171913 0.023436 869303 C T
1 rs13302957 0.024116 891021 G A
1 rs59986066 0.024183 893462 C T
1 rs112905931 0.024260 896271 C T
1 rs6696609 0.024457 903426 C T
```

```
rs3094315 1 0.020130 752566 G A
rs12124819 1 0.020242 776546 A G
rs28765502 1 0.022137 832918 T C
rs7419119 1 0.022518 842013 T G
rs950122 1 0.022720 846864 G C
rs113171913 1 0.023436 869303 C T
rs13302957 1 0.024116 891021 G A
rs59986066 1 0.024183 893462 C T
rs112905931 1 0.024260 896271 C T
rs6696609 1 0.024457 903426 C T
```

PLINK binary y EIGENSTRAT.

Fichero de anotación de las variantes

- **.ind (EIGENSTRAT)** contienen **3 columnas**, en el siguiente orden:

1. ID del individuo
2. Sexo (M, F o U)
3. Grupo poblacional

```
I0040 U Peru_Lauricocha_5800BP
I0041 U Peru_Lauricocha_8600BP
I0308 U Argentina_ArroyoSeco2_7700BP
I1748 U Argentina_ArroyoSeco2_7200BP
Lapa01 U Brazil_LapaDoSanto_9600BP
Lapa25 U Brazil_LapaDoSanto_9600BP
```

- **.fam (PLINK)** son algo más completos (diseñados para estudios de genética epidemiológica). **6 columnas:**

1. ID de la familia del individuo (se puede usar para indicar el grupo poblacional),
2. ID del individuo,
3. ID del padre biológico (0 si no está presente en el conjunto de datos),
4. ID de la madre biológica (0 si no está presente),
5. Sexo biológico (1 = hombre, 2 = mujer, 0 = desconocido),
6. Valor fenotípico (también suele utilizarse para indicar el grupo poblacional).

```
Peru_Lauricocha_5800BP I0040 0 0 0 Peru_Lauricocha_5800BP
Peru_Lauricocha_8600BP I0041 0 0 0 Peru_Lauricocha_8600BP
Argentina_ArroyoSeco2_7700BP I0308 0 0 0 Argentina_ArroyoSeco2_7700BP
Argentina_ArroyoSeco2_7200BP I1748 0 0 0 Argentina_ArroyoSeco2_7200BP
Brazil_LapaDoSanto_9600BP Lapa01 0 0 0 Brazil_LapaDoSanto_9600BP
Brazil_LapaDoSanto_9600BP Lapa25 0 0 0 Brazil_LapaDoSanto_9600BP
```


PLINK binary y EIGENSTRAT.

Fichero de anotación de los individuos

Archivo `.snp.txt` :

:

```
snp1 1 0.1001 100000 A C
snp2 1 0.6162 600000 T G
snp3 2 0.5125 513341 C G
snp4 4 0.1512 251334 G A
```

Archivo `.ind.txt` :

```
IndA M Pop1
IndB M Pop1
IndC F Pop2
IndD M Pop3
```


Archivo `.geno.txt` :

```
0 192
1 122
2 222
0 211
```

Podemos interpretar que el individuo **IndA**, perteneciente a la **población 1**, presenta los siguientes genotipos:

- `snp1` : C/C
- `snp2` : T/G
- `snp3` : faltante
- `snp4` : A/A

Posiciones de Transversiones



Mayor **estabilidad** química de las **transversiones**

Romper y reformar enlaces químicos más drásticos


—> Menos propensos a generarse espontáneamente durante la degradación post-mortem

Inestabilidad de las **transiciones**

Modificaciones químicas más simples

—> ocurren más fácilmente en condiciones de degradación

Parentesco



El parentesco puede inferirse con datos genéticos

—> evaluar si **dos individuos comparten una proporción de regiones genómicas idénticas** mayor que la **esperada por azar**.

En **ADN antiguo**, esta **aproximación se ve dificultada** por:

- la baja cobertura
- la fragmentación molecular
- alto nivel de daño postmortem

—> **información disponible reducida**

—> **mayor incertidumbre** en la estimación de la identidad genómica compartida.

Parentesco: PMR (Pairwise Mismatch Rate)

- Fracción de posiciones del genoma en las que ambos individuos tienen datos válidos (no faltante) con **genotipos distintos**.

—> Cuantifica el grado de discrepancia genética entre dos individuos.

- En una muestra de varios individuos, se asume que la mayoría no son aparentados

—> El **valor de PMR sin parentesco** se puede definir como **la mediana** $\bar{p}$

—>El valor esperado de PMR por grado k es $p_k = \bar{p} \left(1 - \frac{1}{k+1}\right)$.

